

Чанк 900 или 1400? Chroma или Weaviate?

Матрица размеров чанка 500–1400 × два бэкенда на боевом корпусе (heading-aware, 230 документов) + класс «грязных» вопросов

Вопрос пришёл из ревью Антона: поэкспериментировать с размером чанка 1200–1600 знаков и проверочными «грязными» вопросами. Мы прогнали 8 изолированных хранилищ (500/50, 600/100, 900/120, 1400/250 × Chroma/Weaviate) — прод-база, конфиг и коллекции не тронуты. Каждый прогон: 176 тестов, всего 8 прогонов через живой пайплайн (оркестратор → retrieval → генерация), свежий кэш, отдельный eval-визитор.

Короткий ответ (8 ячеек, 1408 тестов): вилка 500–1400 знаков качество не меняет — всё в пределах шума одиночного прогона. Лучшие ячейки — малый чанк (Chroma 600/100 = 161, Weaviate 500/50 = 160) против базы Chroma 900/120 = 160; лёгкий перевес «мельче» на классе С есть на обоих бэкендах, но статистически не отделяется. Рекомендация: рабочую конфигурацию пока не менять; настоящий прирост — вне чанкинга: полнота корпуса (9 устойчивых провалов С) и «грязные» формулировки (класс Х). Бонус: Chroma систематично быстрее Weaviate на р95, оба далеко внутри критерия.

ПОЧЕМУ ЦИФРЫ НИЖЕ ПРОШЛЫХ ПРОГОНОВ? КОРПУС ИЗМЕНИЛСЯ — HEADING-AWARE НАРЕЗКА

30.08 чанковка корпуса была переведена на heading-aware, и в прошлых приёмочных прогонах её ещё не было — поэтому абсолютные цифры этого эксперимента нельзя сравнивать с приёмочными прогонами 28–29.08 (93,5% и 24/24). Внутри эксперимента все 8 ячеек идут на одном и том же новом корпусе, так что их сравнение корректно.

Что сломалось и зачем изменение. Старая нарезка резала документы скользящим окном 900/120 без учёта структуры: узкая секция «Контакты» из FAQ (254 символа) валилась внутри 900-символьного чанка вместе с посторонним текстом. Такой «разбавленный» чанк проигрывал косинусную близость (0,33 против 0,45 у лидеров выборки; изолированная секция давала бы 0,65) — ассистент честно отказывался отвечать на вопросы, ответы на

которые в документах были. Теперь документ режется по заголовкам: атомарная секция становится самостоятельным чанком, окно остаётся только для секций-«переростков».

Цена изменения: тот же корпус нарезан мельче и точнее — 3285 → 7656 чанков; после перевода контрольные вопросы («контакты», «что такое n8n», «что такое RAG»), ранее дававшие ложный отказ, отвечаются корректно. Эксперимент этого окна и проверял: не потеряет ли новая, более мелкая нарезка качество на остальных классах — и не выйдет ли крупный чанк 1400/250 лучше.

Побочно при переезде исправлен дефект конвертера markdown → plain: мусорные > -хвосты HTML-тегов не попадают в тексты чанков.

ИТОГ ПО ПРОГОНАМ (8 ЯЧЕЕК: 500 · 600 · 900 · 1400)



Разброс 6 тестов между крайними ячейками — на границе шума одиночного прогона. Средние по размерам чанка (2 бэкенда): 500 → 159.5 · 600 → 160 · 900 → 157.5 · 1400 → 157.5 — лёгкий перевес малого чанка, одинаково на обоих бэкендах, но для утверждения нужны повторные прогоны. Ядро проверок — идентичность проектов, алиасы, anti-hallucination, отказы на фейках, инъекции, краевые формулировки — устойчиво во всех восьми ячейках.

КЛАСС С — СОДЕРЖАТЕЛЬНЫЕ ВОПРОСЫ О ПРОЕКТАХ (77 ТЕСТОВ)

Главный интерес: влияет ли размер чанка на детали о проектах. По 8 ячейкам — почти нет.

ПРОГОН	С — ВЕРНО	%	P95, МС
Chroma 500/50	65/77	84.4	2159
Weaviate 500/50	66/77	85.7	2412
Chroma 600/100	66/77	85.7	2234
Weaviate 600/100	63/77	81.8	2661
Chroma 900/120 база	64/77	83.1	2212
Weaviate 900/120	61/77	79.2	2380
Chroma 1400/250	61/77	79.2	2290
Weaviate 1400/250	64/77	83.1	2515

Ключевое наблюдение (по 8 прогонам): **9 тестов падают в 7–8 ячейках из 8** (assistant-flow, hr-assistant-speed, telegram-intake, prompt-review и др.) — это не чанкинг, а места, где нужный якорный текст физически недостижим или отсутствует в корпусе. Ещё 11 переключаются стохастически. Средний С по размерам чанка: 500 → 65.5, 600 → 64.5, 900 → 62.5, 1400 → 62.5 — перевес малого чанка в 2–3 теста, однонаправленно на обоих бэкендах, но статистически на границе шума.

КЛАСС X — «ГРЯЗНЫЕ» ВОПРОСЫ (НОВЫЙ, 8 ТЕСТОВ)

5/8 · 4/8 · 5/8 · 5/8 (500) · 5/8 · 5/8 · 4/8 · 5/8 (500–1400) — 4–5 из 8 во всех ячейках, без влияния размера чанка. Формулировки без пунктуации, с опечатками, транслитом, два-в-одном — ассистент справляется.

Стабильные 3 отказа: размытый бизнес-вопрос, «срочно нужно!», «а кто вообще это делает?» — на эмоциональных/размытых фразах

Это отдельная, честная зона роста, не зависящая от чанков: обработка «грязных» формулировок живёт в понимании запроса (системный промпт, переформулировка вопроса), а не в нарезке документов.

alias-распознавание в грязных формулировках: 4/8 — ожидаемо слабое, это и есть материал для следующей итерации промпта.

ассистент уходит в уточнение вместо
полезного ответа.

ЛАТЕНСИ: ЧТО РЕАЛЬНО ВЛИЯЕТ, А ЧТО НЕТ

По каждому из 8 прогонов пайплайн размечен по стадиям (retrieval / generation) на 176 запросах, без кеш-попаданий:

	RETRIEVAL P50	RETRIEVAL P95	GENERATION P50	TOTAL P95
Chroma (4 размера чанка)	167–177 мс	218–243 мс	1150–1260 мс	2677–2972 мс
Weaviate (4 размера чанка)	136–151 мс	174–297 мс	1258–1295 мс	3049–3370 мс

Размер чанка на латенси не влияет. Retrieval — 2–11% общего времени, его p50 почти одинаков в диапазоне 500–1400 знаков; объём генерации тоже не растёт (средняя длина ответа 485–501 знак, источников в контексте ~4 — всюду одинаково).

Доминирует генерация (85–90% времени): p50 ~1.2 с — это скорость LLM, а не retrieval. Разброс total p95 между прогонами одного конфига — до 700 мс, отдельные выбросы класса М до 9 с — стохастика модели.

Систематичный фактор другой — бэкэнд: Chroma стабильно быстрее Weaviate на p95 на ~100–450 мс во всех четырёх парах (пример: класс С p95 — 2159–2290 против 2380–2661 мс). Оба с запасом внутри критерия 5000 мс.

ПОБОЧНЫЙ РЕЗУЛЬТАТ: НАЙДЕН ЛАТЕНТНЫЙ ДЕФЕКТ WEAVIATE

Что случилось. Первая заливка в экспериментальные Weaviate-классы молча потеряла ~3% корпуса (6 из 230 документов, включая крупнейшие гайды) — без единой ошибки в логах.

Root cause. Text-свойство `document_id` создаётся с дефолтной токенизацией `word` : на таком поле фильтр удаления матчит чужие документы, чьи имена файлов распадаются на тот же набор токенов (например, вставка `USER_GUIDE.md` стирала `ORCHESTRATOR_USER_GUIDE.md`).

Масштаб риска. Для нынешнего прода — ноль (активен Chroma, там удаление точное). Но при будущем переключении бэкенда на Weaviate первый же ресинк KB потерял бы эти документы. Зафиксировано как отдельная задача на фикс токенизации.

ЧТО ИМЕННО СТАБИЛЬНО ПАДАЕТ — КАРТА РАБОТ ПО КОРПУСУ

Из 77 тестов класса C **9 падают в 7–8 из 8 ячеек** — инвариантно к размеру чанка и бэкенду. Это не статистика, это адрес конкретных текстов:

ПАДАЕТ В	ТЕСТЫ (ПРОЕКТ → ПРОБЕЛ)
8/8	assistant-flow: принцип работы · hr-assistant: скорость ответа · telegram-intake-bot: сценарий, используемый LLM · telegram-onboarding-bot: ценность · prompt-review: назначение, решаемая проблема
7/8	assistant-flow: консоль · lead-qualification: назначение
6/8	review-flow: принцип · meeting-audit-bot: каналы · telegram-onboarding-bot: сценарий

Проверка на всех ячейках отфильтровала стохастику: остальное переключается прогонами (11 тестов), и его не стоит чинить точноно — это подгонка под бенчмарк. Содержательная работа — найти в корпусах репозиторийев разделы, отвечающие на девять перечисленных вопросов, или добавить их; после правки — один контрольный ресинк.

РЕКОМЕНДАЦИЯ

- **Конфиг не менять:** вилка 500–1400 на качество не влияет (разброс ≤6 тестов); при heading-aware нарезке 900 ограничивает только секции-переростки. Если подтверждать

перевес малого чанка — нужны повторные прогоны, это отдельное решение.

- **Бэкенд-паритет подтверждён на полном контуре:** Weaviate с собственной индексацией даёт то же качество; на латенси Chroma систематично быстрее на p95, но оба далеко внутри критерия 5 с. Резервный бэкенд готов (после дефект-фикса удаления).
- **Следующие итерации — не про размер чанка:**
 - 1) закрыть 9 устойчивых пробелов класса C (см. таблицу выше) — правки корпуса + один контрольный ресинк;
 - 2) научить ассистента не отмалчиваться на «грязных» формулировках (X-vague-business, X-urgency, X-casual-who) — системный промпт;
 - 3) зафиксировать токенизацию свойств в Weaviate до какого-либо бэкенд-переключения.

МЕТОД (ДЛЯ ВОСПРОИЗВОДИМОСТИ)

Корпус: 230 документов / 14 GitHub-источников, строго read-only из прод-синка 30.08 (heading-aware нарезка).

Хранилища: 8 изолированных — chroma-коллекции

`ai_portfolio_knowledge_exp500/_exp600/_exp900/_exp1400` и weaviate-классы

`AiPortfolioChunkExp500...Exp1400` в тех же контейнерах, прод-коллекции не затронуты. Чанков: 9282 (500/50) · 8645 (600/100) · 7656 (900/120) · 7279 (1400/250); сверка «создано vs сохранено» и постатейная сверка с эталоном — 0 расхождений. Тест-план: полный план eval-регресса (классы A–M, 168 тестов) + 6 инъекций + класс X (8 «грязных» вопросов); свежий кэш в памяти, отдельные eval-визиторы на каждый прогон. Ограничение: один прогон на ячейку без повторных заходов — различия в 1–6 тестов статистически не отделяются от LLM-шума; цифры ячеек сравнимы напрямую между собой, но не с eval-отчётом 28–29.08 (другой корпус и режим кеша).

AI Automation Portfolio Lab · кейс AI Portfolio · эксперимент по запросу Антона Хапинского (ревью 29.08) · сырые данные: `eval/chunkexp-2026-08-31/` · 8×176 тестов → 1408 вызовов живого пайплайна